


İndirgenebilir ve İndirgenemez Hata

Toplam beklenen hata iki kaynağa ayrışır: azaltılabilenler ve azaltılamayanlar.

$$\text{MSE} = \text{Bias}^2(f) + \text{Var}(f) + \sigma^2$$

▲
İndirgenebilir


İndirgenebilir Hata
($\text{Bias}^2 + \text{Varyans}$)



Model iyileştirilerek azaltılabilir

▲
İndirgenemez

İndirgenemez Hata
($\sigma^2 - \text{Gürültü}$)



Hiçbir model azaltamaz — verinin doğasında var

Yanlılık (Bias)

Modelin sistematik olarak gerçek değerden sapması; yanlış varsayımlardan kaynaklanır.

Tanım: $\text{Bias}(f; x) = E[f(x)] - f(x) \rightarrow$ Farklı eğitim setlerindeki tahminlerin ortalaması ile gerçek değer arasındaki fark.

Nasıl Oluşur?

- Model gerçek ilişkiyi öğrenemeyecek kadar basit
- Yanlış model ailesi seçimi (örn. doğrusal $\neq$ doğrusal olmayan)
- Eksik özellikler / yetersiz kapasite


Belirtileri

- Hem eğitim hem test hatası yüksek
- Eğitim setinde bile kötü performans
- Model veriyi öğrenemiyor


Çözüm Yolları

- Daha karmaşık model kullan
- Daha fazla özellik (feature) ekle
- Regularizasyonu azalt ($\lambda \downarrow$)

Yanlılık (Bias)
Sistemik Sapma



Yanlı vs Yansız
Tahmin Dağılımı



Varyans (Variance)

Modelin eğitim verisindeki küçük değişimlere karşı duyarlılığı; kararsızlık ölçüsüdür.

Tanım: $\text{Var}(\hat{f}; x) = E[(f(x) - E[f(x)])^2] \rightarrow$ Tahminlerin kendi ortalamaları etrafındaki yayılımı.

Nasıl Oluşur?


- Model eğitim verisine gereğinden fazla uyuyor
- Gürültüyü de öğreniyor — ezberleme
- Parametreler aşırı serbest / regularizasyon yok

Belirtileri


- Eğitim hatası düşük, test hatası yüksek
- Farklı veri setlerinde tutarsız sonuçlar
- Büyük train-test performans farkı

Çözüm Yolları

- Daha fazla eğitim verisi
- Regularizasyon ekle (L1/L2)
- Dropout, Early Stopping, Ensemble



Farklı eğitim setlerinde tahminler birbirine yakın



Farklı eğitim setlerinde tahminler çok farklı

Aşırı Uyum (Overfitting)

Model eğitim verisini, içindeki gürültüyü de dahil ederek ezberler; yeni veriye genellemez.

Koşul: $MSE_{train} \ll MSE_{test}$

Hata: $Bias^2 \downarrow$, $Var \uparrow \uparrow \rightarrow MSE \uparrow$

Sebepler

- Çok karmaşık model (yüksek derece polinom, derin ağ)
- Az eğitim verisi — gürültü öğreniliyor
- Regularizasyon yok veya çok zayıf

Tanırma

- Eğitim skoru %99, test skoru %65 gibi büyük fark
- Öğrenme eğrisinde train-val ayrışması
- Yeni veri geldiğinde tahminler tutarsız

Önleme

- Regularizasyon: Ridge (L2), Lasso (L1)
- Erken durdurma (Early Stopping)
- Dropout, Veri artırma, Çapraz doğrulama

Yetersiz Uyum (Underfitting)

Model verideki temel yapıyı ve ilişkiyi öğrenemeyecek kadar basit ya da kısıtlıdır.

Koşul: $MSE_{train} \approx MSE_{test}$ (ikisi de yüksek)

Hata: $Bias^2 \uparrow\uparrow$, $Var \downarrow \rightarrow MSE \uparrow$

Sebepler


- Çok basit model (doğrusal $\neq$ doğrusal olmayan veri)
- Aşırı güçlü regularizasyon (λ çok büyük)
- Yetersiz eğitim süresi / iterasyon

Tanım

- Hem eğitim hem test hatası yüksek ve yakın
- Model veriyi açıklayamıyor
- Öğrenme eğrisi düşük bir platoda takılı

Çözüm

- Daha karmaşık / derin model kullan
- Regularizasyonu azalt ($\lambda \downarrow$)
- Daha fazla özellik türet (Feature Engineering)



λ (Lambda)

λ Azalır $\rightarrow$ Karmaşıklık Artar (High Variance) $\leftarrow$ $\rightarrow$ λ Artar $\rightarrow$ Baskılama Artar (High Bias)

Amaç: İki hatanın toplamını minimize eden denge.


Sınıflandırma ve Kümeleme Örnekleri:

KÜMELEME


Bias – Variance Tradeoff

(KMeans)


Underfitting ($k=2$, Az Küme)



İyi Fit
(k=4, Doğru Küme Sayısı)



Overfitting
(k=10, Fazla Küme)





BIAS – VARIANCE TRADEOFF · Sınıflandırma Görselleştirmesi

Underfitting
(Yüksek Bias, Düşük Varyans)

İyi Fit
(Dengeli Bias & Varyans)

Overfitting
(Düşük Bias, Yüksek Varyans)



Model çok basit – veriyi öğrenemiyor

Model doğru karmaşıklıkta – iyi genelliyor

Model çok karmaşık – gürültüyü ezberliyor

Uygulamalar

Bias-variance analizinin bazı uygulamaları şunlardır:

1.Model Seçimi: İyi bir genelleme sağlamak için basit mi yoksa karmaşık bir modelin mi daha uygun olduğunu belirlemeye yardımcı olur.

2.Hiperparametre Ayarı: Öğrenme oranı, düzenlileştirme (regularization) katsayısı veya ağaç derinliği gibi parametrelerin hatayı azaltacak şekilde ince ayarını yönlendirir.

3.Model Değerlendirme: Eğitim ve test performansını karşılaştırarak underfitting (yetersiz öğrenme) ve overfitting'i (aşırı öğrenme) tespit etmeye yardımcı olur.

4.Hata Analizi: Tahmin hatalarının temel nedenlerini belirlemeyi ve model stratejilerini buna göre geliştirmeyi sağlar.

5.Topluluk (Ensemble) Öğrenme: Birden fazla modeli birleştirerek bias ve varyansı dengeler; böylece kararlılık ve doğruluk artar.

Avantajlar

Bias ve varyans kavramlarını anlamamanın bazı avantajları şunlardır:

1.Model Doğruluğunu Artırır: Görülmemiş veriler üzerinde tutarlı performans gösteren modeller geliştirmeyi sağlar.

2.Verimli Eğitim Sürecini Destekler: Gereksiz derecede karmaşık veya aşırı öğrenmiş modellerden kaçınarak hesaplama kaynaklarını korur.

3.Yorumlanabilirliği Artırır: Model hatalarının arkasındaki nedenleri anlamayı ve açıklamayı kolaylaştırır.

4.Model Karmaşıklığını Yönlendirir: Farklı veri boyutları ve problemler için en uygun model karmaşıklık düzeyini bulmaya yardımcı olur.

Doğruluk (Accuracy) Tuzağı



- **Senaryo:** 100 hastanın 95'i sağlıklı, 5'i hasta.
- **Hatalı Model:** Herkese "Sağlıklı" diyen kör bir model.
- **Sonuç:** %95 Doğruluk başarısı yalandır.

****Dengesiz veri setlerinde doğruluk metriği yanıltıcıdır.****