

Makine Öğrenmesinde

ÖZELLİK SEÇME

Feature Selection

Filtre • Sarma • Gömülü Yöntemler | Matematiksel Arka Plan

Neden Özellik Seçme?

Boyutluluk Laneti (Curse of Dimensionality)

Özellik sayısı d arttıkça gerekli örnek sayısı üstel büyür: $N \propto e^d$ — model performansı düşer, hesaplama maliyeti artar.

↓ Aşırı Öğrenme

Gereksiz özellikler gürültü ekler;
model eğitim verisine aşırı uyum sağlar.

⚡ Hesap Verimliliği

Daha az özellik = daha hızlı eğitim ve tahmin süreci.

🔍 Yorumlanabilirlik

Az sayıda özellik modelin kararını açıklamayı kolaylaştırır.

📈 Genelleme

Alakasız değişkenler kaldırılınca test doğruluğu genellikle artar.

Hedef: d orijinal özellikten $k < d$ özellik seç $\rightarrow f: \mathbb{R}^d \rightarrow \mathbb{R}^k$ dönüşümü ile en iyi tahmin performansını koru

Üç Ana Yaklaşım

FİLTRE

Filter Methods

Model Bağımsız

Özellikler modelden bağımsız
istatistiksel skorla sıralanır
Düşük hesaplama maliyeti
Hızlı, ön işlem adımı uygun

Yöntemler:

- Pearson Korelasyonu
- Chi-Kare Testi
- Mutual Information
- ANOVA F-testi
- Varyans Eşiği

SARMA

Wrapper Methods

Model Tabanlı

Özellik alt kümesi seçimi için
model performansını kullanır
Yüksek doğruluk, yavaş
Küçük d için uygundur

Yöntemler:

- Forward Selection
- Backward Elimination
- Recursive Feature Elim.
- Exhaustive Search
- Stepwise Selection

GÖMÜLÜ

Embedded Methods

Eğitimle Birlikte

Özellik seçimi model eğitimi
ile eş zamanlı gerçekleşir
Hız ve doğruluk dengesi
Büyük veri setleri için ideal

Yöntemler:

- LASSO (L1 Reg.)
- Ridge / Elastic Net
- Karar Ağacı Önemi
- Random Forest Imp.
- Gradient Boosting

Filtre Yöntemleri — Matematiksel Temel

Pearson Korelasyonu

$$r(X,y) = \Sigma(x_i - \bar{x})(y_i - \bar{y}) / [\sqrt{\Sigma(x_i - \bar{x})^2} \cdot \sqrt{\Sigma(y_i - \bar{y})^2}]$$

$r \in [-1, +1]$ | $|r|$ büyük $\rightarrow$ özellik ilgili

Sadece doğrusal ilişkiyi ölçer

Chi-Kare Testi (Kategorik)

$$\chi^2 = \Sigma_i \Sigma_j (O_{ij} - E_{ij})^2 / E_{ij}$$

$$E_{ij} = (\text{satır toplamı} \times \text{sütun toplamı}) / N$$

$H_0: X \text{ ve } y \text{ bağımsız} \rightarrow \text{yüksek } \chi^2 \text{ reddet}$

Mutual Information

$$I(X;Y) = \Sigma_x \Sigma_y p(x,y) \cdot \log[p(x,y)/(p(x)p(y))]$$

$I = 0 \rightarrow$ bağımsız, I büyük $\rightarrow$ yüksek bağımlılık

Doğrusal olmayan ilişkileri de yakalar

ANOVA F-Testi

$$F = \text{MSB} / \text{MSW} = [\Sigma_k n_k (\bar{y}_k - \bar{y})^2 / (K-1)] / [\Sigma \Sigma (y_{ik} - \bar{y}_k)^2 / (N-K)]$$

MSB: sınıflar arası varyans, MSW: sınıf içi varyans

Yüksek F $\rightarrow$ özellik sınıfları ayırt edebilir

Varyans Eşiği: $\text{Var}(X_j) < \text{threshold} \rightarrow$ özelliği çıkar (bilgi taşımayan sabit benzeri özellikler elenir)

Sarma Yöntemleri — Arama Stratejileri

Forward Selection & Backward Elimination

- 1 Forward: Boş kümeden başla $S = \{\}$
- 2 Her özelliği tek tek ekle, CV ile skorla
- 3 En yüksek skoru veren özelliği ekle: $S = S \cup \{j^*\}$
- 4 Durma kriteri sağlanana dek tekrar et
- 5 Backward: Tüm özelliklerle başla, en az katkısı çıkar

Karmaşıklık: $O(d^2)$ model değerlendirmesi gerektirir

Recursive Feature Elimination (RFE)

Algoritma:

1. f ile tüm özellikler üzerinde model eğit
2. Ağırlık/önem skorlarını hesapla: $|w_j|$
3. En düşük skorlu özellikleri çıkar
4. İstenen özellik sayısına ulaşına dek tekrarla

Çapraz Doğrulama ile RFE (RFECV):

$$k^* = \operatorname{argmax}_k \text{CV_score}(S_k)$$

Optimal k özellik sayısı otomatik belirlenir

Karmaşıklık: $O(d)$ iterasyon $\times O(\text{eğitim maliyeti})$

Gömülü Yöntemler — Düzenleştirme Temelli

LASSO — L1 Düzenleştirme

Maliyet Fonksiyonu:

$$J(w) = \sum_i (y_i - w^T x_i)^2 + \lambda \cdot \sum_j |w_j|$$

Anahtar Özellik:

λ arttıkça bazı w_j tam olarak 0'a gider.

Bu özelliği otomatik olarak seçmemizi sağlar.

Geometrik Yorum:

L1 kısıt bölgesi köşeli (elmas) — çözüm genellikle eksenlerde kesişir $\rightarrow$ seyrek w

λ seçimi: Çapraz doğrulama ile optimal λ bulunur

Ridge — L2 Düzenleştirme

$$J(w) = \sum (y_i - w^T x_i)^2 + \lambda \cdot \sum w_j^2$$

Ağırlıkları küçültür ama tam 0 yapmaz.

Özellik seçmez, katsayı küçültür.

Elastic Net

$$J(w) = \sum (y_i - w^T x_i)^2 + \lambda_1 \sum |w_j| + \lambda_2 \sum w_j^2$$

L1 ve L2'yi birleştirir.

$\alpha = \lambda_1 / (\lambda_1 + \lambda_2)$ karışım oranı

Gruplu değişkenlerde LASSO'dan üstün

Ağaç Tabanlı Önem Skorları

Safsızlık Azalmasına Dayalı Önem

Tek Ağaç İçin:

$$\text{Imp}(j) = \sum_t [p(t) \cdot I(t) - p(tL) \cdot I(tL) - p(tR) \cdot I(tR)]$$

t: j. özelliği kullanan düğüm, I: safsızlık (Gini/Entropi)

Random Forest İçin (MDI):

$$\text{Imp}_{\text{RF}}(j) = (1/T) \cdot \sum_t \sum_t \Delta \text{impurity}(j, t)$$

T ağaç üzerinden ortalama alınır

Permütasyon Önemi (MDA):

$$\text{Perm}(j) = \text{OOB_error}(X_j \text{ karıştırılmış}) - \text{OOB_error}$$

j. özellik karıştırıldığında hata ne kadar artar?

MDI (Safsızlık)

✓ Hızlı hesaplanır
Eğitimle birlikte

✗ Yüksek kardinaliteli
değişkene yanlı

MDA (Permütasyon)

✓ Daha güvenilir
Test setinde hesaplanır

✗ Yavaş
(T × N hesap)

SHAP Değerleri

✓ Yerel + global
Tüm modellerde çalışır

✗ Hesaplama ağır
Karmaşık yorumlama

$$\text{SHAP: } \phi_j = \sum [|S|! (d - |S| - 1)! / d!] \cdot [f(S \cup \{j\}) - f(S)]$$

Yöntem Karşılaştırması & Pratik Rehber

Yöntem	Hız	Doğruluk	Yorumlanabilirlik	Büyük Veri
Pearson / ANOVA	●●●●●	●●●●○	●●●●●	●●●●●
Chi-Kare	●●●●●	●●●●○	●●●●○	●●●●●
Mutual Information	●●●●○	●●●●○	●●●●○	●●●●○
Forward Selection	●●○○○	●●●●○	●●●●○	●●○○○
RFE	●●●●○	●●●●●	●●●●○	●●●●○
LASSO	●●●●○	●●●●○	●●●●●	●●●●●
RF Importance	●●○○○	●●●●●	●●●●○	●●●●○

Öneri: Büyük veri + hız → LASSO/RF | Az veri + yorumlanabilirlik → Pearson/Chi-Kare | En iyi doğruluk → RFE+CV

Özet & Uygulama Pipeline'ı

1

Veriyi Anla

Dağılım, korelasyon matrisi, eksik değer analizi

2

Filtre Uygula

Düşük varyans ve yüksek korelasyonlu özellikleri çıkar

3

Model Tabanlı

LASSO veya RF önemi ile aday özellik kümesi belirle

4

RFE / CV

Çapraz doğrulama ile optimal k özellik sayısını bul

5

Doğrula

Seçilen kümede model performansını test seti ile ölç