

Regresyon Modelleri

Klasikten Güncele: OLS, Ridge, Lasso, Polinom ve RANSAC

OLS

Ridge

Lasso

Polinom

RANSAC

Regresyon Nedir?

Temel Kavram

Regresyon; bağımsız değişken(ler) X ile bağımlı değişken y arasındaki ilişkiyi öğrenen denetimli öğrenme yöntemidir.

Amaç: X bilindiğinde y'nin sürekli (sayısal) değerini tahmin etmek.

Günlük hayattan örnekler:

- Ev fiyatı tahmini (m², konum → fiyat)
- Hisse senedi değeri
- Enerji tüketim tahmini

Matematiksel Gösterim

Basit Doğrusal:

$$y = \beta_0 + \beta_1 x + \varepsilon$$

Çoklu Doğrusal:

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n + \varepsilon$$

Polinom:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_n x^n$$

Matris biçimi:

$$\hat{y} = X\beta$$

OLS – En Küçük Kareler Regresyonu

Amaç: Artıkların (residuals) kareleri toplamını minimize et $\rightarrow SSE = \sum (y_i - \hat{y}_i)^2$

Analitik Çözüm (Normal Denklem)

$$\beta = (X^T X)^{-1} X^T y$$

- Kapalı form çözümü mevcut
- Hesaplama: $O(n \cdot p^2)$ – büyük veri için yavaş
- Aykırı değerlere duyarlı
- Gürültülü veriyle yanlış sonuç üretebilir

Python Kodu

```
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score

model = LinearRegression()
model.fit(X_train, y_train)

y_pred = model.predict(X_test)

print(model.coef_)      #  $\beta_1 \dots \beta_p$ 
print(model.intercept_) #  $\beta_0$ 
print(r2_score(y_test, y_pred))
```

Regülerizasyon: Ridge & Lasso



Neden? OLS, yüksek boyutlu ya da çok korelasyonlu verilerde aşırı öğrenir (overfitting). Regülerizasyon katsayıları kısıtlayarak modeli sadeleştirir.

Ridge Regresyon (L2)

$$SSE + \alpha \cdot \sum \beta_i^2$$

- Tüm katsayıları sıfıra yaklaştırır, hiçbirini tam sıfır yapmaz
- Çoklu doğrusallıkta güçlü
- α hiperparametresi CV ile seçilir
- sklearn: Ridge(alpha= α)

Lasso Regresyon (L1)

$$SSE + \alpha \cdot \sum |\beta_i|$$

- Bazı katsayıları tam sıfır yapar → Özellik seçimi!
- Seyrek (sparse) modeller üretir
- Yüksek boyutlu verilerde tercih edilir
- sklearn: Lasso(alpha= α)

Polinomiyal Regresyon

Temel Fikir

Doğrusal modeli polinom özelliklerle zenginleştirir; model özü itibarıyla hâlâ doğrusaldır — parametrelerde.

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \dots + \beta_n x^n$$

- Derece 1 → Doğrusal (OLS ile özdeş)
- Derece 2 → Parabol (kuadratik)
- Derece 3+ → Daha karmaşık eğriler
- ⚠ Yüksek derece = Overfitting riski
- sklearn: `PolynomialFeatures(degree=d)`

Pipeline

```
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import \
    PolynomialFeatures
from sklearn.linear_model import \
    LinearRegression

model = Pipeline([
    ('poly',
     PolynomialFeatures(
         degree=3)),
    ('ols',
     LinearRegression())
])

model.fit(X_train, y_train)
y_pred = model.predict(X_test)
```

RANSAC – Sağlam (Robust) Regresyon

Problem: OLS, tek bir aykırı değerden bile büyük ölçüde etkilenebilir. RANSAC bunu çözer.

Algoritma Adımları

1. Rastgele küçük alt küme seç
2. Model uydur (min_samples)
3. Tüm noktaları sınıflandır:
İnlier / Outlier (residual_threshold)
4. İyi model adaysa kaydet
5. max_trials kez tekrarla
6. En iyi adayı seç, tüm inlier'lar
ile modeli yeniden eğit

Kullanım & Parametreler

```
from sklearn.linear_model import (
    RANSACRegressor,
    LinearRegression)


ransac = RANSACRegressor(
    estimator=LinearRegression(),
    min_samples=0.5,
    residual_threshold=5.0,
    max_trials=200,
    random_state=42
)
ransac.fit(X, y)

# İnlier maskesi
mask = ransac.inlier_mask_
print(f'İnlier: {mask.sum()}')
```

Modeller Arası Karşılaştırma

Model	Kriter	Güçlü Yönü	Zayıf Yönü	Ne Zaman Kullan?
OLS	SSE	Hızlı, analitik çözüm	Aykırı değer & overfitting	Temiz, az boyutlu veri
Ridge	$SSE + \alpha \cdot \sum \beta^2$	Çoklu doğrusallık	Özellik seçimi yapmaz	Tüm özellikler anlamlı
Lasso	$SSE + \alpha \cdot \sum \beta $	Özellik seçimi (sparse)	Büyük α 'da bilgi kaybı	Yüksek boyutlu, seyrek veri
Polinom	SSE	Doğrusal olmayan örüntüler	Yüksek derecede overfitting	Eğrisel ilişkiler
RANSAC	Consensus	Aykırı değerlere çok dayanıklı	Deterministik değil, yavaş olabilir	Gürültülü / kirli veri

Python Demo – Grafik Sonuçları



OLS
 $\beta_1 \approx 2.07$

Ridge
 $\beta_1 \approx 2.04$

Lasso
 $\beta_1 \approx 0.89^*$

Polinom
 $R^2 \uparrow$

RANSAC
 $\beta_1 \approx 2.50 \checkmark$

Hangi Modeli Ne Zaman Kullanmalı?



Verini temiz mi?
Özellik sayısı az mı?

OLS ile başla



Özellikler arasında
yüksek korelasyon var mı?

Ridge kullan



Gereksiz özellikler
var olabilir mi?

Lasso kullan



İlişki eğrisel mi?

Polinom dene



Veri gürültülü ya da
aykırı değer çok mu?

RANSAC kullan

Teşekkürler!

Özet

OLS → Ridge → Lasso → Polinom → RANSAC

- Regresyon; veriyi en iyi temsil eden parametreleri öğrenmektir.
- Regularizasyon overfitting'i önler; L1 özellik seçer, L2 sadece kısar.
- RANSAC gürültülü ve kirli verilerde OLS'tan çok daha güvenilirdir.
- Model seçimi: veri yapısına, boyuta ve gürültüye göre değişir.