

Mesafe ve Benzerlik Ölçütleri

Distance and Similarity Measures

Makine Öğrenmesine Giriş




Motivasyon

- Benzerlik ve mesafe ölçütleri veri bilimi uygulamalarının merkezindedir.
- Kullanım alanları: Makine öğrenmesi, bilgi erişimi, metin madenciliği, görüntü işleme, bilgisayarlı görü, doğal dil işleme, anomali tespiti, kümeleme ve sınıflandırma.
- Uygun ölçütün seçimi model performansını doğrudan etkiler.

Yakınlık Görecelidir: Yanlış Harita Sizi Yanlış Yere Götürür

- **Sorun:** Çoğu araştırmacı varsayılan olarak Öklid (Euclidean) mesafesini kullanır. Ancak her veri seti bu geometriye uymaz.
- **Kanıt:** Sıkıştırılmış görüntü geri getirme görevlerinde standart Öklid mesafesi düşük performans gösterirken, Canberra ve Wave-Hedges metrikleri hem verimlilik hem de doğruluk sağlar.
- **Çıkarım:** 'Mesafe' kavramı sabit değildir; verinin doğasına göre şekillenir.



Benzerlik ve Mesafe Arasındaki Fark

Benzerlik Ölçütü

Nesneler daha benzer oldukça değer büyür.


Mesafe Ölçütü

Nesneler daha benzer oldukça değer küçülür;
aynıysa genellikle 0 olur.

Çoğu zaman biri diğerinden türetilebilir.

Temel Kavramlar: Benzerlik ve Mesafe İlişkisi

- **Benzerlik:** Skor arttıkça nesneler birbirine daha çok benzer.
- **Mesafe:** Skor azaldıkça nesneler birbirine daha çok benzer (0 = Özdeş).
- **Genel Kural:** $\text{Sim}(A,B)$ yükseldikçe, $\text{Dist}(A,B)$ düşer.




Bir 'Metrik' Olmanın Altın Kuralları

Matematiksel olarak $d: X \times X \rightarrow \mathbb{R}$ fonksiyonunun bir "metrik" sayılması için üç şartı sağlaması gerekir:


1. **Ayırt Edilemezlik:** $d(x, y) = 0 \iff x = y$
2. **Simetri:** $d(x, y) = d(y, x)$
3. **Üçgen Eşitsizliği:** $d(x, y) \leq d(x, z) + d(z, y)$

Not: Kosinüs Mesafesi gibi popüler ölçümler, üçgen eşitsizliğini ihlal ettikleri için teknik olarak metrik değildir.




$$d(x, y) \leq d(x, z) + d(z, y)$$

Yön ve Aç: İç Çarpım (Inner Product) Ailesi




- Bu aile, verileri vektör uzayında ele alır. Odak noktası genellikle vektörlerin yönüdür.
- **İç Çarpım Formülü:** $sim_{IP}(P, Q) = \langle P, Q \rangle$
- **Kullanım:** İkili (binary) vektörlerde eşleşme sayısını ölçmek için temel yöntemdir.
- **Mantık:** P ve Q vektörlerinin örtüşmesi, onların "benzerliğini" tanımlar.

Kosinüs Benzerliği (Cosine Similarity)



- Vektörlerin büyüklüğüne (magnitude) değil, yönüne odaklanır.
- **Formül:** $sim_{Cos} = \frac{\langle P, Q \rangle}{\|P\| \|Q\|}$
- **Aralık:** $[-1, 1]$
- **Kritik Detay:** Üçgen eşitsizliğini sağlamadığı için 'Kosinüs Mesafesi' teknik olarak bir metrik değildir.


Açısal Mesafe (Angular Distance)




$$d_{Ang} = \frac{\arccos(sim_{Cos})}{\pi}$$

- Kosinüs benzerliğini geçerli bir metriğe dönüştürür.
- **Avantajı:** $[0, 1]$ aralığında normalize edilmiş gerçek bir metriktir. Üçgen eşitsizliğini sağlar.
- **Dezavantajı:** 'arccos' fonksiyonunun hesaplanması yavaştır, büyük veri setlerinde maliyetli olabilir.

Kümeler Arası Benzerlik: Jaccard ve Dice




Jaccard İndeksi: Kümelerin ne kadar örtüştüğünü ölçer. Gerçek bir metriktir (1 - Jaccard).




Dice Katsayısı: Örtüşmeyi ortalama büyüklüğe göre değerlendirir. Üçgen eşitsizliğini ihlal eder.

- **Kullanım Alanları:** Metin madenciliği, genetik sekans analizi.


Uzamsal Mesafe: Minkowski Ailesi (L_p)



L1 (Manhattan)




L2 (Euclidean)



L_∞ (Chebyshev)


- Uzayı: Öklid ve Manhattan mesafelerinin genelleştirilmiş halidir.
- Formül: $L_p(P, Q) = (\sum |P_i - Q_i|^p)^{1/p}$
- Parametre 'p' değiştikçe, uzayın geometrisi ve 'yakınlık' algısı değişir.

Öklid Mesafesi (L2 - Euclidean)



- **Tanım:** İki nokta arasındaki 'kuş uçuşu' mesafe. Pisagor teoremine dayanır.
- **Karesel Öklid (Squared Euclidean):** İşlemden tasarruf etmek için karekökün alınmadığı versiyonudur. Hesaplama maliyetini düşürür ancak üçgen eşitsizliğini sağlamaz.
- **Kullanım:** Sayısal veriler için standart yaklaşım.

Manhattan Mesafesi (L1 - City Block)



- **Tanım:** Izgara tabanlı bir şehirde iki nokta arasındaki seyahat mesafesi.
- **Formül:** $\sum |P_i - Q_i|$
- **Neden Kullanılır?**
 - Ayırık (discrete) özellikler için daha uygundur.
 - Yüksek boyutlu uzaylarda Öklid'e göre aykırı değerlere karşı daha dirençlidir.

Sayısal Örnekler — Örnek Vektörler

$$\mathbf{P} = (1, 2, 3)$$

$$\mathbf{Q} = (2, 4, 6)$$

*Önemli özellik: $\mathbf{Q} = 2\mathbf{P} \rightarrow$ Yönleri aynı, büyüklükleri farklı!
Bu nedenle kosinüs/açısal ölçütler tam benzerlik gösterecek.*

Sayısal Örnekler — Mesafe Hesapları

Öklidyen (L_2)

$$\begin{aligned} & \sqrt{[(1-2)^2 + (2-4)^2 + (3-6)^2]} \\ &= \sqrt{1 + 4 + 9} = \sqrt{14} \approx 3.74 \end{aligned}$$

Karesi Alınmış (L_2^2)

$$\begin{aligned} & (1-2)^2 + (2-4)^2 + (3-6)^2 \\ &= 1 + 4 + 9 = 14 \end{aligned}$$

Manhattan (L_1)

$$\begin{aligned} & |1-2| + |2-4| + |3-6| \\ &= 1 + 2 + 3 = 6 \end{aligned}$$

İç Çarpım $\langle P, Q \rangle$

$$\begin{aligned} & 1 \cdot 2 + 2 \cdot 4 + 3 \cdot 6 \\ &= 2 + 8 + 18 = 28 \end{aligned}$$

Sayısal Örnekler — Benzerlik Hesapları

Normlar:

$$\|P\| = \sqrt{14}, \quad \|Q\| = \sqrt{56} = 2\sqrt{14}$$

Kosinüs Benzerliği

$$28 / (\sqrt{14} \cdot 2\sqrt{14}) = 28/28 = 1$$

→ Tamamen aynı yön!

Açısal Mesafe

$$\arccos(1)/\pi = 0/\pi = 0$$

→ sim_ang = 1

Jaccard Benzerliği

$$28 / (14+56-28) = 28/42 \approx 0.67$$

Dice Benzerliği

$$(2 \cdot 28) / (14+56) = 56/70 = 0.8$$

Ölçütlerin Karşılaştırılması | $P=(1,2,3)$, $Q=(2,4,6)$

Ölçüt	Değer	Metrik?	Ne ölçer?
L_2 Mesafesi	≈ 3.74	Evet	Mutlak uzaklık
L_1 Mesafesi	6	Evet	Mutlak uzaklık (Manhattan)
Kosinüs Benzerliği	1	Hayır	Yön benzerliği
Açısal Mesafe	0	Evet	Yön farkı
Jaccard Benzerliği	≈ 0.67	Evet	Örtüşme oranı
Dice Benzerliği	0.8	Hayır	Örtüşme oranı

Karar Rehberi: Hangi Ölçümü Seçmeliyim?

Matematiksel bir 'metrik' olması şart mı? O zaman Angular veya Jaccard tercih edin.



Özet

Benzerlik ve mesafe ölçütleri, veri bilimi algoritmalarının temelidir.

Her ölçüt her problem için uygun değildir.

Veri tipi (sayısal, ikili, küme, metin) seçimi belirler.

Problem türü (kümeleme, sınıflandırma, arama) seçimi etkiler.

Hesaplama maliyeti de göz önüne alınmalıdır.